

TP2 - Modelado Estadístico

Predicción del score de IMDB en un catálogo de streaming

Emiliano Torres y Federico Leonardis Ayala

2026-08-01

En el catálogo de streaming tenemos 3631 títulos (2365 películas y 1266 series) con su `imdb_score`. El objetivo es predecir ese score para 1652 títulos nuevos, usando pérdida cuadrática.

1. Análisis exploratorio




Figure 1: Izquierda: score medio de IMDB por género, con intervalo de confianza al 95% y cantidad de títulos (línea punteada: promedio global). Derecha: score medio por tipo de título.

La Figura 1 muestra que los géneros con mejor score son **war**, **history** y **documentation**, mientras que **horror** es notoriamente el peor puntuado. Los intervalos de confianza también avisan cuáles diferencias son más sólidas: géneros con pocos títulos (**western**, $n=31$) tienen bandas mucho más anchas que géneros frecuentes (**drama**, $n=1916$), así que conviene leer esas cosas con cautela — un boxplot mostraría la dispersión entre títulos individuales, que es parecida en todos los géneros, y no esa incertidumbre sobre el promedio, que es la que nos interesa ahora. Las series (7.01) puntúan sistemáticamente más alto que las películas (6.28), una diferencia que retomamos en la sección de modelado.




Figure 2: Duración según el tipo de título. Para las series, runtime es la duración de un episodio, no de la temporada completa.

La Figura 2 muestra por qué **runtime** no es directamente comparable entre películas y series: la mediana es 100 minutos para películas pero solo 42 para series, porque ahí se mide la duración de un episodio y no de la temporada. Por eso en la Sección 3 dejamos que el efecto de **runtime** (lineal o vía spline) varíe según el tipo de título, en vez de compartir una única curva entre películas y series.




Figure 3: Score medio vs. cantidad de títulos (escala log), por director (izquierda) y por país principal (derecha). Línea punteada: promedio global. El mismo diagnóstico que vimos con los counties de radon en la clase de modelos mixtos.

La Figura 3 es el mismo diagnóstico “funnel” que vimos con los counties de radon: los grupos con pocos títulos (izquierda de cada panel) se dispersan mucho más lejos del promedio global que los grupos con muchos títulos — eso es ruido, no una diferencia real entre directores o países. La forma de embudo, más marcada en director que en país porque hay muchísimos más directores con 1 o 2 títulos, es exactamente lo que motiva usar un efecto aleatorio en vez de un efecto fijo plano para estas variables: más abajo rankeamos directores y actores con Empirical Bayes en vez de promedio crudo (Tablas 2 y 3), y en la Sección 3 usamos país (y también probamos director) como variable de agrupamiento de un modelo mixto por la misma razón.

Table 1: Correlación de Pearson de variables numéricas con el score de IMDB.

Variable	Correlación con score
Duración (runtime)	-0.135
Año de estreno	-0.103
Cantidad de votos (log10)	0.229
Cantidad de géneros	0.050

Ninguna correlación lineal es fuerte: la más alta es la de los votos (en escala logarítmica), y aun así es moderada. Esto ya anticipa que un modelo puramente lineal va a rendir peor que uno que permita curvas — lo que confirmamos en la Sección 3.

Table 2: Directores mejor rankeados por Empirical Bayes (score crudo incluido para comparar).

Nombre	Titulos	Crudo	Empirical Bayes
Kim Won-seok	3	8.7	8.09
Shin Won-ho	1	9.2	7.75
Bo Burnham	4	8.0	7.66
Rajkumar Hirani	3	8.1	7.65
Alastair Fothergill	1	9.0	7.65

Table 3: Actores mejor rankeados por Empirical Bayes (score crudo incluido para comparar).

Nombre	Titulos	Crudo	Empirical Bayes
David Attenborough	4	8.62	7.52
Terry Jones	6	8.07	7.47
Yui Ishikawa	5	8.24	7.43
Yoshimasa Hosoya	7	8.00	7.42
Aamir Khan	11	7.76	7.41

Table 4: Palabras de la descripción con mayor y menor score medio (≥ 30 apariciones).

Grupo	Palabra	Apariciones	Score medio
Score alto	times	30	7.17
	century	31	7.07
	political	42	7.05
	british	31	7.03
	age	39	6.98
Score bajo	forces	43	5.97
	deadly	30	5.97
	boyfriend	35	5.92
	car	39	5.90
	christmas	77	5.84

Table 5: Palabras del título con mayor y menor score medio (≥ 15 apariciones).

Grupo	Palabra	Apariciones	Score medio
Score alto	dark	15	6.98
	life	39	6.90
	happy	15	6.89
	la	15	6.89
	story	28	6.82
Score bajo	world	22	6.23
	family	18	6.08
	day	22	5.83
	christmas	44	5.79
	super	17	5.75

Para rankear directores y actores usamos **Empirical Bayes** en vez del promedio crudo: ajustamos un modelo mixto sin covariables (`lmer(imdb_score ~ (1 | nombre))`) y usamos la estimación de cada intercept aleatorio como score ajustado — el mismo *partial pooling* Normal-Normal de la clase de modelos mixtos, versión continua del Beta-Binomial que usamos en el TP1 para tasas de adopción. Si rankeamos por el promedio crudo sin ningún filtro, el top 5 de ambas categorías queda dominado por nombres con **un solo título** y un score alto de pura casualidad (por ejemplo, varios actores de una sola serie muy bien puntuada llegan a 9.5 crudo); el ranking por Empirical Bayes en cambio favorece a quienes repiten buenos puntajes en varios títulos (Tablas 2 y 3), sin necesitar un umbral arbitrario de “al menos N títulos” como hubiéramos tenido que imponer con el crudo.

En la Sección 3 retomamos esta misma lógica en los modelos de efectos mixtos: probamos **país** y **director** como variables de agrupamiento (modelos 3 y 4), pero no actor. La razón no es que el shrinkage no funcione con actor — la Tabla 3 muestra que funciona igual de bien, sino que cada título tiene un solo país y, en nuestra simplificación, un solo director principal (el primero acreditado; ~90% de los títulos con director tienen exactamente uno), mientras que puede tener muchos actores. Un efecto aleatorio por actor con más de 36.000 niveles (82% con un solo título) encarece mucho el ajuste sin aportar demasiado sobre lo que ya capturan género y tipo de título. En cuanto al texto (Tablas 4 y 5), tanto en la descripción como en el título las palabras de mayor score remiten a docudramas, historia o relatos de vida (“century”, “political”, “story”, “life”), mientras que las de menor score remiten a comedias románticas o de época festiva (“boyfriend”, “christmas”) — coherente con el patrón por género de la Figura 1.

2. Causalidad




Figure 4: DAG del efecto de Comedia sobre Score.

Nos interesa el efecto causal **directo** de Comedia sobre Score, es decir, el que no pasa por Duración. Según el DAG (Figura 4) hay tres caminos entre Comedia y Score además del efecto directo:

- **Camino 1:** Score $\leftarrow$ País $\rightarrow$ Comedia (País es un confusor común).
- **Camino 2:** Comedia $\rightarrow$ Duración $\rightarrow$ Score (mediación por Duración).
- **Camino 3:** Comedia $\rightarrow$ Duración $\leftarrow$ Año $\rightarrow$ Score (Duración es un *collider* en este camino).

Como buscamos el efecto **no mediado por Duración**, estamos obligados a condicionar por Duración para cerrar el Camino 2. Pero condicionar por un collider lo **abre**: al fijar Duración, el Camino 3 deja de estar bloqueado. Para volver a cerrarlo hay que condicionar también por Año, que es la otra variable de ese camino. Por separado, el Camino 1 solo se cierra condicionando por País, ya que es la única variable en ese camino.

No hay otra combinación posible: Duración es obligatoria por la definición del efecto que buscamos, y una vez que se condiciona por ella, tanto Año como País pasan a ser obligatorios para cerrar los caminos que quedan (o se abren). El **único conjunto de ajuste válido** es $Z = \{\text{País, Año, Duración}\}$.

Table 6: Efecto de Comedia sobre el score: asociación cruda vs. efecto causal directo.

Modelo	Coeficiente de Comedia
Asociación cruda (sin ajustar)	-0.206
Efecto causal directo ($Z = \{\text{País, Año, Duración}\}$)	-0.221

Ajustamos $\text{Score} = \beta_0 + \beta_1 \text{Comedia} + \beta_2 \text{Duración} + \beta_3 \text{Año} + \beta_4 \text{País}$ sobre los datos de entrenamiento. El efecto causal directo estimado es $\hat{\beta}_1 = -0.221$: los títulos que incluyen comedia entre sus géneros tienen, en promedio, 0.22 puntos menos de score que los que no la incluyen, manteniendo fijos duración, año y país. La asociación cruda (-0.206) es muy parecida a la ajustada: la diferencia es de apenas -0.015 puntos. Esto sugiere que, en este dataset, el confounding por País y la mediación por Duración son efectos débiles (o se cancelan parcialmente entre sí) — la asociación cruda ya es un buen proxy del efecto causal directo.

3. Selección de modelos

Evaluamos con **validación cruzada de 5 folds** sobre `titles_train` (en vez de un único split entrenamiento/testeo), para que el MSE de cada modelo no dependa de qué partición aleatoria nos tocó. Probamos siete modelos, usando en cada uno las variables disponibles (duración, año, votos, tipo, certificación de edad, géneros, país, elenco). En todos dejamos que el efecto de `runtime` varíe según `type`, porque en la Sección 1 vimos que `runtime` mide cosas distintas para películas y series:

1. **Lineal base:** `lm` con duración interactuada con tipo, año, votos, certificación y géneros, más el país agrupado (los 9 países más frecuentes + “Otro”) como efecto fijo.
2. **Lineal enriquecido:** el anterior sumando temporadas, cantidad de actores/directores y cantidad de géneros.
3. **Efectos mixtos por país:** intercept aleatorio por país (`lmer`, `(1 | pais)`), con las mismas variables fijas que el modelo 1 (sin el país como efecto fijo, ya que ahora es la variable de agrupamiento).
4. **Efectos mixtos por director:** igual al anterior pero con intercept aleatorio por director principal.
5. **Splines:** `gam` con splines penalizados (`mgcv`) sobre año y votos, y un spline de duración distinto por tipo (`s(runtime, by = type)`), más certificación y géneros como términos paramétricos.
6. **Splines + efecto aleatorio de país:** el modelo 5 sumando un término `s(pais, bs="re")`, combinando splines penalizados con partial pooling por país.
7. **Splines + aleatorio de país + elenco:** el modelo 6 sumando temporadas, cantidad de actores y cantidad de directores (las mismas variables de elenco que en el modelo 2 no habían ayudado casi nada en un contexto lineal, pero acá las volvemos a probar combinadas con splines y partial pooling).

Table 7: MSE promedio de validación cruzada (5 folds) para cada modelo, ordenados de mejor a peor.

Modelo	MSE medio	Desvío entre folds
7. Splines + aleatorio + elenco	0.8980	0.0705
6. Splines + aleatorio (pais)	0.9041	0.0692
5. Splines	0.9095	0.0698
4. Mixto (director)	0.9715	0.0839
3. Mixto (pais)	0.9841	0.0822
2. Lineal enriquecido	0.9901	0.0826
1. Lineal base	0.9911	0.0821

El modelo ganador es el **7 (splines + aleatorio de país + elenco)**, con MSE medio = 0.898 y desvío entre folds de 0.0705. Sumar las variables de elenco al modelo 6 mejora el MSE en la mayoría de los folds, aunque la distancia entre los modelos 6 y 7 (0.0061) es chica frente al desvío entre folds, así que la tomamos con la misma cautela que cualquier diferencia de ese tamaño. Lo que sí es robusto, y se mantiene en los 5 folds, es que los splines superan claramente a los modelos lineales (los efectos de duración, año y votos no son lineales) y que agregar el efecto aleatorio de país siempre ayuda un poco más sobre el spline puro.

Entre los modelos mixtos, el de **director** ($ICC \approx 0.17$, ajustado sobre todo `titles_train`) explica proporcionalmente más varianza entre grupos que el de **país** ($ICC \approx 0.04$), aunque el 85% de los directores tiene un solo título en el dataset: hay señal real en quién dirige, pero es difícil de aprovechar con tan pocos datos por grupo. El país, en cambio, tiene grupos más balanceados y por eso lo elegimos como variable de agrupamiento en el modelo final. Enriquecer el modelo lineal con variables de elenco (modelo 2) prácticamente no había mejorado el MSE respecto del modelo 1 (por eso en un principio las habíamos dejado afuera del modelo ganador), pero combinadas con splines y el efecto aleatorio de país (modelo 7) sí suman algo, así que terminamos incluyéndolas.

Una limitación a tener en cuenta: los modelos 1, 2 y 5 representan el país con las 9 categorías más frecuentes (“país agrupado”, efecto fijo), mientras que los modelos 3, 4, 6 y 7 usan los 79 países completos como variable de agrupamiento de un efecto aleatorio. La comparación de MSE entre familias de modelos mezcla entonces dos decisiones a la vez (splines/mixtos vs. lineal, y cómo se representa el país), no aísla una sola cosa.




Figure 5: Efecto parcial estimado en el modelo ganador: duración (separado por tipo de título), año y votos de IMDB.

La Figura 5 muestra por qué el spline le gana al modelo lineal: el efecto de la duración no es monótono y además tiene una forma distinta para películas que para series (consistente con la Figura 2), y el de los votos se aplana en valores altos — relaciones que un término lineal compartido no puede capturar. Las bandas se ensanchan en los extremos (películas de más de 200 minutos, por ejemplo) porque hay pocos títulos ahí.

4. Competencia

Usamos el modelo ganador (splines + efecto aleatorio de país + elenco), ya ajustado sobre **todo** `titles_train` en la Sección 3, para predecir los 1652 títulos de `titles_test`. Hay 17 títulos cuyo país principal no aparece en el entrenamiento (por ejemplo Vietnam o Irak); para esos usamos como respaldo el modelo 5 (splines sin el término de país ni de elenco), que no depende de esas variables. Las predicciones quedan en `predicciones_Torres_LeonardisAyala.csv`, una columna sin encabezado, en el mismo orden que `titles_test.csv`.

Conclusiones

El score de IMDB depende sobre todo de variables no lineales — duración (con una forma distinta para películas que para series), año y cantidad de votos — y del género y tipo de título, con un margen adicional que aportan el país de producción vía *partial pooling* y el tamaño del elenco. El modelo ganador combina splines penalizados, un efecto aleatorio de país y variables de elenco (cantidad de actores y directores), mejorando el MSE de validación cruzada en cerca de un 9% respecto del modelo lineal base. Las variables de elenco solo aportaron una vez combinadas con splines y *partial pooling*: en un modelo puramente lineal (modelo 2) no habían mostrado ninguna mejora, algo que vale la pena tener presente antes de descartar una variable por cómo rindió en un solo tipo de modelo.

En la sección de causalidad, el efecto directo de Comedia sobre Score resultó similar a la asociación cruda, lo que indica que ni el confounding por país ni la mediación por duración son fuertes en estos datos.

El hilo conductor de la exploración y de la selección de modelos terminó siendo el *partial pooling*: lo usamos para rankear directores y actores con Empirical Bayes en vez de promedio crudo, para elegir la variable de agrupamiento del modelo mixto ganador (país por sobre director, porque tiene grupos menos extremos) y en el modelo final. La lección se repite en cada instancia: el shrinkage ayuda mucho cuando hay grupos de tamaños dispares, pero con miles de directores de un solo título o decenas de miles de actores queda muy poca información por grupo como para que incluso el shrinkage separe bien la señal del ruido.