

TP2 - Modelado Estadístico

Predicción del score de IMDB en un catálogo de streaming

Emiliano Torres y Federico Leonardis Ayala

2026-08-01

En el catálogo de streaming tenemos 3631 títulos (2365 películas y 1266 series) con su `imdb_score`. El objetivo es predecir ese score para 1652 títulos nuevos, usando pérdida cuadrática.

1. Análisis exploratorio

Antes de mirar los datos tomamos algunas decisiones de preparación. Las columnas `genres` y `production_countries` vienen como listas escritas en texto, así que las parseamos: de la primera armamos una indicadora binaria por género (un título puede tener varios) y de la segunda nos quedamos con el primer país, al que llamamos *país principal*. Las categorías de `age_certification` con menos de 20 títulos las juntamos en una categoría “Otra”, y los faltantes quedaron como “Desconocida”, que es una categoría informativa en sí misma porque cubre el 43% del catálogo. Los 13 títulos sin `imdb_votes` se imputaron con la mediana. Un punto importante: todos estos cortes (qué países entran en el grupo de los frecuentes, qué certificaciones sobreviven, el valor de la mediana) se calcularon **únicamente sobre el conjunto de entrenamiento** y después se aplicaron igual al de testeo, para no filtrar información del test hacia el ajuste.




Figure 1: Izquierda: score medio de IMDB por género, con intervalo de confianza al 95% y cantidad de títulos (línea punteada: promedio global). Derecha: distribución completa del score según el tipo de título.

La Figura 1 muestra que los géneros con mejor score son **war**, **history** y **documentation**, mientras que **horror** es notoriamente el peor puntuado. Los intervalos de confianza también avisan cuáles diferencias son más sólidas: géneros con pocos títulos (**western**, $n=31$) tienen bandas mucho más anchas que géneros frecuentes (**drama**, $n=1916$), así que conviene leer esas colas con cautela. Elegimos mostrar el intervalo de

confianza y no un boxplot porque el boxplot describe la dispersión entre títulos individuales, que es parecida en todos los géneros (el desvío ronda 1.1 en casi todos), mientras que acá nos interesa la incertidumbre sobre el promedio, que sí cambia mucho con el tamaño del grupo. Las series (7.01) puntúan sistemáticamente más alto que las películas (6.28), una diferencia que retomamos en la sección de modelado.




Figure 2: Duración según el tipo de título. Para las series, runtime es la duración de un episodio, no de la temporada completa.

La Figura 2 muestra por qué **runtime** no es directamente comparable entre películas y series: la mediana es 100 minutos para películas pero solo 42 para series, porque ahí se mide la duración de un episodio y no de la temporada. Por eso en la Sección 3 dejamos que el efecto de **runtime** (lineal o vía spline) varíe según el tipo de título, en vez de compartir una única curva entre películas y series.




Figure 3: Score medio vs. cantidad de títulos (escala log), por director (izquierda) y por país principal (derecha). Línea punteada: promedio global. Ambos paneles comparten la escala vertical para que la comparación de dispersión sea justa. Es el mismo diagnóstico que vimos con los counties de radon en la clase de modelos mixtos.

La Figura 3 es el mismo diagnóstico “funnel” que vimos con los counties de radon: los grupos con pocos títulos (izquierda de cada panel) se dispersan mucho más lejos del promedio global que los grupos con muchos títulos: eso es ruido, no una diferencia real entre directores o países. La forma de embudo, más marcada en director que en país porque hay muchísimos más directores con 1 o 2 títulos, es exactamente lo que motiva usar un efecto aleatorio en vez de un efecto fijo plano para estas variables: más abajo rankeamos directores

y actores con Empirical Bayes en vez de promedio crudo (Tabla 2), y en la Sección 3 usamos país (y también probamos director) como variable de agrupamiento de un modelo mixto por la misma razón.

Table 1: Correlación de Pearson de variables numéricas con el score de IMDB.

Variable	Correlación con score
Duración (runtime)	-0.135
Año de estreno	-0.103
Cantidad de votos	0.197
Cantidad de votos (log10)	0.229
Cantidad de géneros	0.050

Ninguna correlación lineal es fuerte, pero la tabla deja una decisión tomada: la cantidad de votos se relaciona con el score bastante mejor en escala logarítmica que en la original (0.229 contra 0.197), algo esperable en una variable que va de decenas a millones. Por eso en la Sección 3 todos los modelos usan $\log_{10}$ de los votos. Que aun así ninguna correlación pase de 0.3 anticipa que un modelo puramente lineal va a rendir peor que uno que permita curvas, algo que confirmamos más adelante.

Table 2: Directores y actores mejor rankeados por Empirical Bayes, con el score crudo al lado para comparar.

Rol	Nombre	Titulos	Crudo	Empirical Bayes
Director	Kim Won-seok	3	8.70	8.09
	Shin Won-ho	1	9.20	7.75
	Bo Burnham	4	8.00	7.66
Actor	David Attenborough	4	8.62	7.52
	Terry Jones	6	8.07	7.47
	Yui Ishikawa	5	8.24	7.43

Table 3: Palabras con mayor y menor score medio, en la descripción (≥ 30 apariciones) y en el título (≥ 15).

Fuente	Grupo	Palabra	Apariciones	Score medio
Descripción	Score alto	times	30	7.17
		century	31	7.07
	Score bajo	car	39	5.90
		christmas	77	5.84
Título	Score alto	dark	15	6.98
		life	39	6.90
	Score bajo	christmas	44	5.79
		super	17	5.75

Para rankear directores y actores usamos **Empirical Bayes** en vez del promedio crudo: ajustamos un modelo mixto sin covariables (`lmer(imdb_score ~ (1 | nombre))`) y usamos la estimación de cada intercept aleatorio como score ajustado. Es el mismo *partial pooling* Normal-Normal de la clase de modelos mixtos, versión continua del Beta-Binomial que usamos en el TP1 para tasas de adopción. Si rankeamos por el promedio crudo sin ningún filtro, el top de ambas categorías queda dominado por nombres con **un solo título** y un score alto de pura casualidad (por ejemplo, varios actores de una sola serie muy bien puntuada llegan a 9.5 crudo); el ranking por Empirical Bayes en cambio favorece a quienes repiten buenos puntajes en

varios títulos (Tabla 2), sin necesitar un umbral arbitrario de “al menos N títulos” como hubiéramos tenido que imponer con el crudo.

En la Sección 3 retomamos esta misma lógica en los modelos de efectos mixtos: probamos **país** y **director** como variables de agrupamiento (modelos 3 y 4), pero no actor. La razón no es que el shrinkage no funcione con actor (la Tabla 2 muestra que funciona igual de bien), sino que cada título tiene un solo país y, en nuestra simplificación, un solo director principal (el primero acreditado; alrededor del 90% de los títulos con director tienen exactamente uno), mientras que puede tener muchos actores. Un efecto aleatorio por actor con más de 36.000 niveles, el 82% de ellos con un solo título, encarece mucho el ajuste sin aportar demasiado sobre lo que ya capturan género y tipo de título.

En cuanto al texto (Tabla 3), tanto en la descripción como en el título las palabras de mayor score remiten a docudramas, historia o relatos de vida (“century”, “political”, “story”, “life”), mientras que las de menor score remiten a comedias románticas o de época festiva (“boyfriend”, “christmas”), coherente con el patrón por género de la Figura 1.

2. Causalidad




Figure 4: DAG del efecto de Comedia sobre Score.

Nos interesa el efecto causal **directo** de Comedia sobre Score, es decir, el que no pasa por Duración. Buscamos entonces un conjunto $Z \subseteq \{\text{Año}, \text{Duración}, \text{País}\}$ que bloquee todos los caminos entre Comedia y Score salvo el arco directo. Además de ese arco, en el DAG (Figura 4) hay tres caminos:

- **Camino 1:** $\text{Comedia} \leftarrow \text{País} \rightarrow \text{Score}$, donde País es un *confounder*.
- **Camino 2:** $\text{Comedia} \rightarrow \text{Duración} \rightarrow \text{Score}$, una *cadena* con Duración en el medio.
- **Camino 3:** $\text{Comedia} \rightarrow \text{Duración} \leftarrow \text{Año} \rightarrow \text{Score}$, donde Duración es un *collider* y Año es un confounder entre Duración y Score.

Aplicando el criterio de bloqueo visto en clase, las tres variables quedan forzadas de a una:

- **Duración** $\in Z$. El Camino 2 es una cadena cuyo único nodo intermedio es Duración, así que la única forma de bloquearlo es condicionar por ella. Es exactamente lo que pide la consigna al hablar del efecto *no mediado* por Duración.
- **País** $\in Z$. El Camino 1 tiene un solo nodo intermedio, País, que además es el nodo central de un confounder, así que hay que incluirlo.

- **Año** $\in Z$. El Camino 3 venía bloqueado de entrada, porque Duración es un collider que no estaba en Z y ninguno de sus descendientes tampoco. Pero al agregar Duración en el primer paso ese camino **se abre**, y el único nodo que queda para volver a cerrarlo es Año, que es el nodo central de un confounder entre Duración y Score.

Como las tres variables resultaron obligatorias, ningún otro subconjunto de {Año, Duración, País} sirve: el **único conjunto de ajuste válido es $Z = \{\text{País, Año, Duración}\}$** . Vale la pena notar que el orden del razonamiento importa. Si uno evaluara el Camino 3 antes de decidir sobre Duración, concluiría que ya está bloqueado y que Año es innecesario; recién al condicionar por el collider aparece la necesidad de agregar Año.

Table 4: Efecto de Comedia sobre el score: asociación cruda vs. efecto causal directo.

Modelo	Coficiente de Comedia
Asociación cruda (sin ajustar)	-0.206
Efecto causal directo ($Z = \{\text{País, Año, Duración}\}$)	-0.221

Ajustamos $\text{Score} = \beta_0 + \beta_1 \text{Comedia} + \beta_2 \text{Duración} + \beta_3 \text{Año} + \beta_4 \text{País}$ sobre los datos de entrenamiento. El efecto causal directo estimado es $\hat{\beta}_1 = -0.221$: los títulos que incluyen comedia entre sus géneros tienen, en promedio, 0.22 puntos menos de score que los que no la incluyen, manteniendo fijos duración, año y país. La asociación cruda (-0.206) es muy parecida a la ajustada: la diferencia es de apenas -0.015 puntos. Esto sugiere que, en este dataset, el confounding por País y la mediación por Duración son efectos débiles (o se cancelan parcialmente entre sí): la asociación cruda ya es un buen proxy del efecto causal directo.

3. Selección de modelos

Evaluamos con **validación cruzada de 5 folds** sobre `titles_train` (en vez de un único split entrenamiento/testeo), para que el MSE de cada modelo no dependa de qué partición aleatoria nos tocó. Probamos siete modelos con las variables disponibles (duración, año, votos, tipo, certificación de edad, géneros, país, elenco). Dos decisiones son comunes a todos y salen de la Sección 1: usamos $\log_{10}$ de los votos, porque es la escala en la que esa variable se relaciona con el score, y dejamos que el efecto de `runtime` varíe según `type`, porque mide cosas distintas en películas y en series.

1. **Lineal base**: `lm` con duración interactuada con tipo, año, votos, certificación y géneros, más el país agrupado (los 9 países más frecuentes + “Otro”) como efecto fijo.
2. **Lineal enriquecido**: el anterior sumando temporadas, cantidad de actores/directores y cantidad de géneros.
3. **Efectos mixtos por país**: intercept aleatorio por país (`lmer, (1 | pais)`), con las mismas variables fijas que el modelo 1 (sin el país como efecto fijo, ya que ahora es la variable de agrupamiento).
4. **Efectos mixtos por director**: igual al anterior pero con intercept aleatorio por director principal.
5. **Splines**: `gam` con splines penalizados (`mgcv`, base `bs = "cr"` como en la clase) sobre año y votos, y un spline de duración distinto por tipo, más certificación y géneros como términos paramétricos. Dejamos que `gam` elija la penalización por GCV en vez de fijarla a mano.
6. **Splines + efecto aleatorio de país**: el modelo 5 sumando un término `s(pais, bs = "re")`, que combina splines penalizados con el partial pooling por país.
7. **Splines + aleatorio de país + elenco**: el modelo 6 sumando temporadas, cantidad de actores y cantidad de directores, las mismas variables de elenco que en el modelo 2 casi no habían ayudado en un contexto lineal.

Table 5: MSE promedio de validación cruzada (5 folds) para cada modelo, ordenados de mejor a peor.

Modelo	MSE medio	Desvio entre folds
--------	-----------	--------------------

7. Splines + aleatorio + elenco	0.8587	0.0690
6. Splines + aleatorio (pais)	0.8672	0.0686
5. Splines	0.8767	0.0706
3. Mixto (pais)	0.9265	0.0707
4. Mixto (director)	0.9279	0.0870
2. Lineal enriquecido	0.9349	0.0721
1. Lineal base	0.9376	0.0722

El modelo ganador es el **7 (splines + aleatorio de país + elenco)**, con MSE medio = 0.8587 y desvío entre folds de 0.069. Fue el mejor en los **cinco** folds, así que el resultado no depende de la partición. La jerarquía también es clara: los tres modelos con splines quedan bien por debajo de los cuatro sin splines, lo que confirma que la no linealidad de duración, año y votos es lo que más pesa. Sobre esa base, el efecto aleatorio de país y las variables de elenco aportan mejoras chicas pero consistentes (0.018 puntos de MSE entre el modelo 5 y el 7). Como esas diferencias son chicas frente al desvío entre folds, las leemos como una mejora sostenida y no como una ventaja contundente.

Los dos modelos mixtos quedaron prácticamente empatados (0.9265 para país y 0.9279 para director), pese a que el ICC del agrupamiento por **director** es bastante más alto (0.17 contra 0.06 de **país**). Es decir: hay más señal en quién dirige que en el país de producción, pero es señal difícil de cobrar, porque el 85% de los directores aparece en un solo título.

Para la familia con splines elegimos **país** y no director como variable de agrupamiento, por dos razones prácticas. La primera es de cobertura sobre el test real: el 48% de los títulos de `titles_test` tiene un director que no aparece en el entrenamiento, y otro grupo grande no tiene director acreditado, así que para cerca del 80% del test el efecto aleatorio de director colapsa a la media poblacional y no aporta nada; con país ese problema afecta a solo el 1% de los títulos. La segunda es de costo: ajustar `s(director, bs = "re")` con más de 2.000 niveles tarda más de diez minutos por fold, contra unos pocos segundos con los 80 niveles de país, lo que hacía inviable meterlo en la validación cruzada completa.

Enriquecer el modelo lineal con variables de elenco (modelo 2) casi no mejoró el MSE respecto del modelo 1, pero combinadas con splines y el efecto aleatorio de país (modelo 7) sí aportan, así que terminamos incluyéndolas. Vale como advertencia metodológica: descartar una variable por cómo rindió dentro de una sola familia de modelos puede hacernos perder algo que sí sirve en otra.

Una limitación: los modelos 1, 2 y 5 representan el país con las 9 categorías más frecuentes (efecto fijo), mientras que los modelos 3, 4, 6 y 7 usan los 80 países completos como agrupamiento de un efecto aleatorio. La comparación entre familias mezcla entonces dos decisiones a la vez, no aísla una sola.




Figure 5: Efecto parcial estimado de cada spline del modelo ganador, con banda de dos errores estándar. Las marcas del eje inferior son los valores observados. La duración se estima por separado para películas y series.

La Figura 5 muestra por qué el spline le gana al modelo lineal. El efecto de la duración no es monótono y tiene una forma bien distinta según el tipo: en películas cae hasta los 100 minutos y después sube con fuerza, mientras que en series es casi monótono creciente y mucho más suave (3.4 grados de libertad efectivos contra 7.5 en películas). El de los votos es el término más flexible de todos (8.8 grados de libertad) y crece de forma marcada: son las relaciones que un término lineal compartido no puede capturar. Las bandas se ensanchan en los extremos, donde el rug muestra que hay pocos títulos.

4. Competencia

Usamos el modelo ganador (splines + efecto aleatorio de país + elenco), ya ajustado sobre **todo** `titles_train` en la Sección 3, para predecir los 1652 títulos de `titles_test`. Hay 17 títulos cuyo país principal no aparece en el entrenamiento (por ejemplo Vietnam o Irak); para esos usamos como respaldo el modelo 5 (splines sin el término de país ni de elenco), que no depende de esas variables. Las predicciones quedan en `predicciones_Torres_LeonardisAyala.csv`, una columna sin encabezado, en el mismo orden que `titles_test.csv`.

Conclusiones

El score de IMDB depende sobre todo de variables no lineales (duración, con una forma distinta para películas que para series; año; y cantidad de votos en escala logarítmica), del género y del tipo de título, con un margen adicional que aportan el país de producción vía *partial pooling* y el tamaño del elenco. El modelo ganador combina las tres ideas y mejora el MSE de validación cruzada en cerca de un 8% respecto del modelo lineal base, ganando en los cinco folds.

En causalidad, el efecto directo de Comedia sobre Score resultó muy parecido a la asociación cruda: ni el confounding por país ni la mediación por duración son fuertes acá. Buen recordatorio de que ajustar por el conjunto correcto no siempre cambia el número; el valor del DAG estuvo en poder afirmar que la asociación cruda *es* interpretable causalmente, no en corregirla.

Del proceso de selección nos quedaron dos aprendizajes. Uno es que conviene probar una variable en más de una familia de modelos antes de descartarla: las de elenco no aportaban nada en el lineal y sí combinadas con splines y *partial pooling*. El otro es sobre el *partial pooling*, hilo conductor del trabajo, que también mostró su límite: el agrupamiento por director tiene más señal que el de país (ICC 0.17 contra 0.06) y aun así no nos sirvió, porque para el 80% de los títulos a predecir el director es desconocido o no está acreditado. Que un efecto exista no alcanza: para que ayude a predecir tiene que estar presente en los datos nuevos.